韦泽

首席软件工程师丨Agent 开发、机器学习与应用科学

中国上海丨+86 152 2132 9512丨ze.wei1989@gmail.com

教育背景

南京大学丨中国江苏南京

- **软件工程硕士**丨2011 年 9 月 - 2013 年 6 月
- **软件工程学士**丨2007 年 9 月 - 2011 年 6 月

个人简介

首席软件工程师，拥有 **13 年以上**软件工程经验，涵盖 AI/ML 系统、数据平台和分布式应用。在 Outlook Copilot 项目中，设计邮件与日历工作流的 Agent 工具，主导 GPT-4o-mini 的微调与部署，并构建面向模型训练和评测的**合成数据**管线与**基准评测（benchmark）数据集。注重将应用科学与生产工程相结合**，重点关注数据质量、基于仿真的 Agent 评测、可扩展的模型服务，以及准确率与成本之间的权衡。具备与企业客户及基础设施团队协作，将业务需求转化为 AI 解决方案的经验。

- **LLM 评测与数据质量：** 基准评测数据集设计、数据分布与覆盖度、与人类预期对齐、统计显著性，以及基于仿真的 Agent 性能与可靠性评测。
- **合成数据与数据工程：** 面向模型训练和评测的合成数据生成、在线与离线 ETL、Spark、Kafka，以及分布式批处理和流式处理管线。
- **LLM 微调与模型训练：** 以 GPT-4o 为教师模型的 GPT-4o-mini 微调、BERT/GPT-2 微调、PyTorch、TensorFlow、分类与 NLP 模型，以及模型训练和推理管线。
- **Agent 开发与对话式 AI：** Agent 工具设计与优化、微软 Agent 平台集成、任务型工作流、对话状态管理、知识检索与动作执行。
- **特征工程与检索：** 行为特征、用户与物品嵌入、Wide & Deep CTR 模型、CTR/CVR 预测，以及基于 LSH 的近似最近邻检索。
- **Azure AI 与云服务：** 熟悉 Azure OpenAI 及 Azure 服务生态，具备 Microsoft Purview 实践经验。
- **生产级 AI 与分布式系统：** 模型服务、延迟与成本优化、Linux、Docker、Kubernetes、图存储、数据血缘、分布式链路追踪、REST API 和 WebSocket。
- **编程语言：** Python、Go、Java、C#。

工作经历

微软亚太，上海 — 首席软件工程师丨2025 年 1 月 - 至今

Outlook Copilot：Agent 开发与应用科学

- 设计并优化 Outlook 邮件与日历工作流的 **Agent 工具**，在微软统一 Agent 平台上集成对话式 AI 与任务执行能力。系统性评估工具变更对整体系统的连带影响及新增 Agent 行为，保障 Agent 的稳健性与可靠性。
- 主导 Outlook Copilot 的**基准评测数据集开发**，将最新学术与产业研究成果应用于实际评测设计。关注数据分布的代表性、场景覆盖、结合 LLM-as-judge 评分准则与人类预期开展校准，以及具有统计意义的评测。
- 构建**合成数据生成管线**，支持规模化创建 Outlook Copilot 的训练与评测数据集。
- 与基础设施工程师合作搭建**仿真环境**，评估 Agent 的性能与可靠性。
- 主导面向邮件与日历分类任务的 **GPT-4o-mini 微调与部署**，提高准确率与成本效率。以 GPT-4o 为教师模型，采用 LoRA SFT 开展微调。
- 主导面向 GPT-4o-mini 分类任务的递归式 **Prompt 自动调优**，与 GPT-4o 及微调后的 GPT-4o-mini 基线比较，权衡准确率与成本效率。

Microsoft Azure：图存储与数据血缘 | 2022 年 2 月 - 2024 年 11 月

- 参与 **Microsoft Purview** 的研发。该 Azure 数据治理平台扫描数据资产，并将元数据存储于数据图谱。
- 重点开发 GraphDB 能力，为平台提供核心存储支持。
- 开发数据血缘能力，记录数据资产之间的数据流转与关联关系。
- 与 S500 企业客户合作，分析和理解其数据资产、关联关系及访问模式，帮助客户使用 Purview 有效管理和治理数据。

微软中国，苏州 — 高级软件工程师 | 2020 年 3 月 - 2022 年 1 月

对话式 AI 与模型训练平台

- 构建任务型对话机器人平台，涵盖语句解析、自然语言理解、实体抽取与槽位填充、会话与对话状态管理、知识检索，以及 Webhook 动作执行集成。
- 开展 GPT-2 微调，并实现基于知识图谱引导的话题切换，用于对话机器人。
- 构建**基于 PyTorch 的深度学习管线**，支持工业应用中图像分类模型的训练、验证与服务部署。
- 与 S500 企业客户合作，理解业务需求，为对话式 AI 与模型训练平台提供定制化解决方案。
- 论文（第二作者）：FORCE: A Framework of Rule-Based Conversational Recommender System（AAAI 2022）

触宝科技 — 资深数据科学家 | 2018 年 10 月 - 2020 年 3 月

广告、商品搜索与推荐

- 训练意图分类模型，并微调 BERT，从商品标题与描述中抽取实体和属性。
- 基于用户画像、App 使用情况与点击行为构建特征，用于用户属性预测和 CTR/CVR 模型。
- 利用会话内共现样本，以及点击、购买和安装行为，在共享向量空间中训练**用户与物品嵌入**。
- 在 Wide & Deep CTR 模型中融合人工特征与用户、物品嵌入，相比逻辑回归基线，**AUC 提升 0.005**。
- 基于 Spark 构建 LSH 检索系统，用于相似人群扩展与相似商品检索；在 20 分钟内完成百万行级数据集的近邻关联，性能提升超过五倍。

语音处理与外呼机器人

- 基于 TensorFlow 训练 TDNN 语音活动检测模型，2019 年材料记录的 F1 为 90.54。通过 Go、cgo 和 TensorFlow C 库提供在线服务，平均预测延迟**低于 1 ms**。
- 训练 LSTM 模型，实现自动标点预测与断句，记录的 F1 约为 69.7。
- 基于 Kaldi 构建用于对话系统的实时语音解码器，记录的多线程解码性能提升为 30%。

新氦大数据（Helium2） — 高级算法工程师 | 2017 年 2 月 - 2018 年 10 月

云原生平台工程与大数据分析

- 构建端到端的 Kubernetes 监控平台，涵盖数据采集、后端服务、报表、告警与自愈。
- 使用 **Spark 和 Kafka** 构建可扩展的批处理与流式处理管线，支持数据转换、聚合、限流与负载均衡。
- 将机器学习与时间序列模型应用于日志和指标分析，实现异常检测、故障预测与根因分析。
- 开发分布式链路追踪能力，并基于 OpenTSDB 和 Elasticsearch 存储数据，用于分析性能瓶颈、流量流转与服务依赖关系。

百度 — 软件工程师 | 2013 年 7 月 - 2017 年 1 月

全栈平台、分布式调度与 AI 数据采集

- 交付涵盖 Web 工具、Android 客户端与 REST API 的**全栈应用**，支持任务发布与数据采集。
- 基于 WebSocket 和异步 I/O 设计事件驱动服务，实现跨 Windows、Linux 和移动设备的高吞吐、低延迟任务调度。
- 构建可配置的移动端 UI 组件和第三方 SDK，无需更新应用即可支持新的数据采集工作流。
- 开发大规模数据采集与标注工作流，服务于图像识别、自动驾驶及搜索与广告排序优化等机器学习应用。
- 专利：《监控服务质量的方法、服务端、客户端及系统》（英文名称：Method, Server, Client, and System for Monitoring Service Quality）。